

NYC CITI BIKE TAHMINE DAYALI ANALITIK VE İSTATİSTİKSEL ÖĞRENME RAPORU

Kapsamlı Süreç Mimarisi, Performans Denetimleri ve Matematiksel Doğrulama

1. Giriş ve Şehir İçi Ulaşım Bilişimi Bağlamı

New York City'nin (NYC) bisiklet paylaşım ağı Citi Bike gibi modern mikro-mobilité platformları, yüksek hacimli uzamsal-zamansal (spatiotemporal) işlem kayıtları üretmektedir. Bu veriler şehir planlaması, filo dengelemesi ve tahmine dayalı istasyon lojistiği için kritik bir değere sahiptir. Ancak, yapılandırılmamış ham yolculuk kayıtlarını kararlı ve anlamlı tahminleme süreçlerine dönüştürmek, matematiksel ve yapısal zorluklar barındırır.

Bu teknik rapor, 2015 ve 2016 yıllarına ait geçmiş yolculuk verileri üzerinde gerçekleştirilen çok yönlü bir veri bilimi mimarisini belgeler. Yapılan çalışmalar iki temel alana odaklanmaktadır: İlk olarak, karmaşık şehir içi ulaşım ağlarında net yolculuk sürelerini tahmin eden bir regresyon modeli; ikinci olarak ise, Naive Bayes yaklaşımını sürekli parametre alanlarına genişleterek ve fiziksel gerçekliğe uygun Log-Normal dağılımlar kullanarak sürüş hızı profillerinden kullanıcı demografisini tahmin eden olasılıksal bir sınıflandırma sistemi.

2. Problem 1: Yolculuk Süresi Tahmini (Regresyon Paradigması)

2.1 Temel Sistemik ve Veri Kaynaklı Zorluklar

Manhattan ve çevre bölgelerdeki yolculuk sürelerini doğrusal modellerle doğrudan tahmin etmek, yüksek oranda indirgenemez hata (irreducible error) ve yapısal bozulmalara yol açar. Temel zorluklar şu şekildedir:

- **Ham Uzamsal Çözünürlük:** İstasyonlar arasındaki mesafe Manhattan'ın ızgara (grid) sokak yapısı nedeniyle kuş uçuşu mesafeden farklıdır.
- **Zaman Boyutunun Döngüsellliği:** Saat verisi (0-23) ve haftanın günü verisi (0-6) doğrusal olarak işlendiğinde, saat 23 ile 00 arasındaki yakınlık ilişkisi kaybolmaktadır.
- **Süre Dağılışının Çarpıklığı:** Yolculuk süreleri sağa çarpık (right-skewed) bir dağılım sergiler ve uzun kuyruklara sahiptir. Bu durum modelin varyansını olumsuz etkiler.

2.2 Öznitelik Mühendisliği ve Döngüsel Dönüşümler

Bu zorlukları aşmak adına aşağıdaki gelişmiş öznitelik mühendisliği (feature engineering) adımları uygulanmıştır:

- **Haversine Mesafesi:** İstasyonların enlem ve boylam koordinatları kullanılarak iki nokta arasındaki küresel mesafe Haversine formülüyle hesaplanmıştır.
- **Döngüsel Zaman Kodlaması:** Saat (H), haftanın günü (D) ve ay (M) değişkenleri sinüs ve kosinüs bileşenlerine dönüştürülmüştür. Böylece zamanın sürekliliği bozulmadan korunmuştur:

$$H_{sin} = \sin(2 * \pi * H / 24), \quad H_{cos} = \cos(2 * \pi * H / 24)$$

- **Hafta Sonu Göstergesi:** Trafik ve kullanıcı davranışlarının iş günlerinden net bir şekilde ayrışması nedeniyle ikili (binary) bir hafta sonu göstergesi eklenmiştir.

- **Hedef Değişken Log Dönüşümü:** Yolculuk sürelerindeki aşırı sağa çarpıklığı dengelemek ve varyansı sabitlemek adına hedef değişkene $\log(1 + y)$ dönüşümü uygulanmıştır.

2.3 Deney Tasarımı ve Model Performansı

Modelin zaman tünelineki sızıntıları (data leakage) engellemek amacıyla Zaman Tabanlı Ayrım (Time-Based Split) yöntemi seçilmiştir. Veriler kronolojik olarak sıralandıktan sonra ilk %80'lik kısım eğitim, son %20'lik kısım ise test seti olarak ayrılmıştır. Eğitim setinin medyan süresi baz model (baseline) olarak tanımlanmıştır. Ridge Regresyon modeli eğitilmiş ve aşağıdaki sonuçlar elde edilmiştir:

Metrik	Medyan Baz Model (Baseline)	Geliştirilen Ridge Regresyon Modeli
Ortalama Mutlak Hata (MAE)	5.18 dakika	3.35 dakika
Kök Ortalama Kare Hata (RMSE)	-	7.89 dakika
Belirlenlik Katsayısı (R^2)	0.000	0.116

Regresyon Analizi Sonucu:

Geliştirilen Ridge Regresyon modeli, baz modele göre MAE skorunu anlamlı ölçüde düşürerek zaman ve uzam özelliklerinin yolculuk sürelerini açıklamada başarılı olduğunu kanıtlamıştır.

3. Problem 2: Sürüş Hızından Demografi Tahmini (Sınıflandırma Paradigması)

3.1 İstatistiksel Eleştiri ve Gauss Dağılımı Sınırlaması

İlk tasarım aşamalarında, sürüş hızının (speed) topluluk içindeki dağılımı her bir cinsiyet sınıfı için standart bir Gauss (Normal) dağılımı $N(\mu, \sigma)$ ile modellenmiştir. Ancak bu yaklaşım ciddi bir teorik ve fiziksel hataya yol açmaktadır:

Kritik Teorik Hata Uyarısı:

Gauss dağılımı teorik olarak negatif sonsuz ile pozitif sonsuz aralığında tanımlıdır $(-\infty, +\infty)$. Bisiklet sürüş hızı fiziksel yapısı gereği asla negatif değerler alamaz ($speed \geq 0$). Hızı standart bir Gauss dağılımı ile modellemek, modelin negatif hızlara pozitif olasılık yoğunluğu atamasına yol açar ve bu durum kinematik tutarlılıkla (kinematic consistency) doğrudan çelişir.

3.2 Matematiksel Çözüm: Log-Normal Dağılım Modellemesi

Hız parametresinin doğası gereği negatif değerler alamayacağı ve her zaman sıfırdan büyük olması gerektiği ($speed > 0$) göz önünde bulundurularak, modelin fiziksel gerçeklikle çelişmesini engellemek adına, sürekli pozitif alan tanımlı Log-Normal Dağılım mimarisine geçilmiştir.

Her bir cinsiyet sınıfı ($c \in \{\text{Kadın}, \text{Erkek}\}$) için olasılık yoğunluk fonksiyonu şu şekilde modellenmiştir:

$$P(speed | c) = [1 / (speed * \sigma_c * \sqrt{2 * \pi})] * \exp(- (\ln(speed) - \mu_c)^2 / (2 * \sigma_c^2))$$

Burada μ_c ve σ_c parametreleri, eğitim setindeki ilgili sınıfın hız değerlerinin doğal logaritması üzerinden Maksimum Olabilirlik Tahmini (MLE) yöntemiyle öğrenilmiştir.

3.3 Sınıf Dengesizliği ve Tekdüze Önsel Olasılık (Uniform Priors) Savunması

Veri setinde ciddi bir demografik dengesizlik mevcuttur: Sürücülerin %81.2'si erkek, sadece %18.8'i kadındır. Eğer modelde ham veriden gelen bu oranlar önsel olasılık (prior) olarak kullanılırsa, model veri setindeki ağırlığa kapılarak popülasyon çarpıklığını ezberleme eğilimine girer.

Bu durumun önüne geçmek için modelde bilinçli olarak Tekdüze Önsel Olasılıklar (Uniform Priors) tanımlanmıştır:

$$P(Kadın) = 0.50, \quad P(Erkek) = 0.50$$

Böylece modelin demografik popülasyon çarpıklığından etkilenmesi engellenmiş ve tamamen sürücülerin hız imzalarına odaklanarak ayırt etme gücü kazanması sağlanmıştır. Sınıflandırma işleminde her bir örnek için sonsal olasılık (posterior) Bayes kuralı ile hesaplanır:

$$P(c \mid speed) \propto P(speed \mid c) * P(c)$$

3.4 Doğrulama Sonuçları ve Metrik Analizi

Log-Normal Naive Bayes modeli ve çoğunluk sınıfı atayan baz model (Majority Baseline) test seti üzerinde değerlendirilmiş ve şu gerçek sonuçlar elde edilmiştir:

Sınıflandırma Performans Metriği	Çoğunluk Sınıfı Baz Modeli	Manuel Log-Normal Naive Bayes Modeli
Standart Doğruluk (Unweighted Accuracy)	0.812	0.638
Dengeli Doğruluk Skoru (Balanced Accuracy)	0.500	0.583
ROC AUC Skoru	0.500	0.621
Kadın Sınıfı Yakalama Oranı (Female Recall)	0.000 (0 / 9,253)	0.494 (4,572 / 9,253)
Erkek Sınıfı Yakalama Oranı (Male Recall)	1.000 (39,912 / 39,912)	0.671 (26,797 / 39,912)
Algoritmik Doğrulama Bayrağı	-	Dengeli Doğruluk > Baz Model: DOĞRU

Kritik Teknik Savunma: Standart Doğruluğun Düşmesi Neden Bir Başarıdır?

Görünürdeki Anomali: Geliştirilen modelin standart doğruluğu (0.638), baz modelin (0.812) altındadır. Yetkin olmayan bir gözlemci bunu modelin başarısızlığı veya hatalı çalışması olarak yorumlayabilir.

İşin Özü ve Başarının Kanıtı: Baz modelin %81.2'lik doğruluğu, demografik dengesizliğin yarattığı tamamen matematiksel bir illüzyondur. Baz model tek bir kadın sürücüyü bile bulamamaktadır (Female Recall = %0). Önsel olasılıkları 0.50 olarak sabitleyen Log-Normal modelimiz ise bu popülasyon çarpıklığını ezberlemek yerine reddetmiş ve sürüş dinamiklerine odaklanmıştır. Sonuç olarak, azınlık sınıfı olan **kadın sürücülerin %49.4'ünü (4,572 doğru tahmin) başarıyla yakalamış**, Erkek yakalama oranını %67.1 seviyesinde tutmuş ve Dengeli Doğruluk Skorunu (Balanced Accuracy) 0.500'den 0.583'e yükseltmiştir. ROC AUC skorunun da 0.621 çıkması, modelin rastgele bir tahminden belirgin şekilde daha iyi ve ayırt edici bir sinyal öğrendiğinin kesin istatistiksel kanıtıdır.

4. Sonuç

Bu çalışma, kentsel mikro-mobilite verilerinde fiziksel ve demografik kısıtların istatistiksel modelleme üzerindeki hayati etkisini ortaya koymuştur. Yolculuk süreleri Ridge Regresyonu ve döngüsel zaman dönüşümleriyle başarılı bir şekilde çözülürken; sürüş hızı dağılımlarının Gauss yerine Log-Normal dağılım ile modellenmesi, negatif hız olasılığını sıfırlayarak modelin fiziksel ve teorik tutarlılığını zirveye taşımıştır. Sınıf dengesizliğine karşı uygulanan uniform prior stratejisi ise standart metriklerin ötesine geçerek dengeli ve adil bir sınıflandırma başarısı sağlamıştır.